

# Неделя 1. МНК. Дополнительные материалы

## Обозначения

Есть ряд математических понятий, которые в разных источниках имеют разные обозначения. Приведём здесь обозначения нашего курса максимально чётко, чтобы избежать путаницы в дальнейшем!

- $E(y_i)$  — математическое ожидание случайной величины  $y_i$ . В других источниках можно встретить обозначение  $M(y_i)$ .
- $Var(y_i)$  — дисперсия случайной величины  $y_i$ . В других источниках можно встретить обозначение  $D(y_i)$ ,  $V(y_i)$ .
- $Cov(y_i, x_i)$  — ковариация случайных величин  $y_i$  и  $x_i$ ,  $Cov(y_i, x_i) = E(y_i x_i) - E(y_i)E(x_i)$ .
- $Corr(y_i, x_i)$  — корреляция случайных величин  $y_i$  и  $x_i$ ,  $Corr(y_i, x_i) = Cov(y_i, x_i) / \sqrt{Var(y_i)Var(x_i)}$ .
- $sCov(y, x)$  — выборочная (s — сокращение от sample) ковариация векторов  $y_1, \dots, y_n$  и  $x_1, \dots, x_n$ ,  $sCov(y_i, x_i) = \sum (y_i - \bar{y})(x_i - \bar{x}) / (n - 1)$
- $sVar(y)$  — выборочная дисперсия вектора  $y_1, \dots, y_n$ ,  $sVar(y_i, x_i) = \sum (y_i - \bar{y})^2 / (n - 1)$
- $sCorr(y, x)$  — выборочная корреляция векторов  $y_1, \dots, y_n$  и  $x_1, \dots, x_n$ ,  $sCorr(y, x) = sCov(y_i, x_i) / \sqrt{sVar(y_i)sVar(x_i)}$ .

Особую путаницу может вызвать обозначение RSS и ESS! Будьте очень бдительны! В данном курсе:

- $RSS$ , сумма квадратов остатков, residual sum of squares,  $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ .
- $ESS$ , объясненная сумма квадратов остатков, explained sum of squares,  $ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ .

В других источниках можно столкнуться совершенно с противоположным обозначением (!!!), а именно,  $RSS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$  (regression sum of squares, регрессионная сумма квадратов),  $ESS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  (error sum of squares, сумма квадратов ошибок прогноза)

Меньше разногласий вызывают обозначения:

- Вектор зависимой переменной

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

- Вектор ошибок модели

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- Матрица всех регрессоров (на примере двух объясняющих переменных):

$$X = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}$$

- Вектор прогнозных значений:

$$\hat{y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{pmatrix}$$

- Знакомьтесь, вектор из единиц

$$\vec{1} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

- Вектор остатков,  $\hat{\varepsilon} = y - \hat{y}$ ,

$$\hat{\varepsilon} = \begin{pmatrix} \hat{\varepsilon}_1 \\ \hat{\varepsilon}_2 \\ \vdots \\ \hat{\varepsilon}_n \end{pmatrix}$$

- Вектор неизвестных коэффициентов

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix}$$

- Оценки неизвестных коэффициентов

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{pmatrix}$$

- Транспонирование матрицы мы будем обозначать штрихом,  $A'$ . В других источниках можно встретить обозначение  $A^T$ .

Модель в скалярной записи:

$$y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$$

Оцененная регрессия:

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i + \hat{\beta}_3 z_i$$

Модель в матричном виде:

$$y = X\beta + \varepsilon$$

Оценённая регрессия в матричном виде:

$$\hat{y} = X\hat{\beta}$$

## Оценки коэффициентов в матричном виде

На примере модели  $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$  мы установили, что остатки,  $\hat{\varepsilon}_i$  ортогональны регрессорам:

$$\begin{cases} \vec{1} \perp \hat{\varepsilon} \\ x \perp \hat{\varepsilon} \\ z \perp \hat{\varepsilon} \end{cases}$$

Другими словами, столбцы матрицы регрессоров  $X$  ортогональны остаткам регрессии, вектору  $\hat{\varepsilon}$ :

$$X' \hat{\varepsilon} = 0$$

Заметим, что здесь  $0$  — это вектор размера  $k \times 1$ . Подставляем формулу для остатков,  $\hat{\varepsilon} = y - X\hat{\beta}$ :

$$X'(y - X\hat{\beta}) = 0$$

Раскрываем скобки и переносим в разные стороны уравнения:

$$X'y - X'X\hat{\beta} = 0$$

$$X'X\hat{\beta} = X'y$$

Матрица  $X'$  имеет размер  $k \times n$ , поэтому на неё сокращать нельзя. Хотя иногда хочется :) А вот обратная матрица к матрице  $X'X$  существует, если среди столбцов  $X$  нет линейно зависимых и  $n \geq k$ . Домножаем обе части уравнения слева на  $(X'X)^{-1}$ :


$$\hat{\beta} = (X'X)^{-1}X'y$$

Ура! Мы получили формулу для МНК-оценок множественной регрессии! Заметьте, что она подозрительно похожа на формулу МНК-оценки для случая одного оцениваемого параметра. В модели  $y_i = \beta x_i + \varepsilon_i$  МНК-оценка коэффициента  $\beta$  будет иметь вид

$$\hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{1}{\sum x_i^2} \sum x_i y_i$$

Матрица-шляпница

Если  $\hat{\beta} = (X'X)^{-1}X'y$ , то вектор прогнозов,  $\hat{y}$ , будет равен  $\hat{y} = X\hat{\beta} = X(X'X)^{-1}X'y$ . Матрицу  $H = X(X'X)^{-1}X'$  по-английски называют “hat-matrix”, матрицей-шляпницей, потому, что она надевает на  $y$  шляпку:  $\hat{y} = H \cdot y$ . Умножение любого вектора на матрицу  $H$  проецирует этот вектор на пространство, порождаемое регрессорами.



Поскольку сами регрессоры уже лежат в этом пространстве, то  $H \cdot X = X$ . Матрица  $H$  идемпотентная, то есть возведенная в произвольную натуральную степень даст саму себя,  $H^n = H$ . В этом легко можно убедиться либо перемножив руками  $H$  на  $H$ ,

$$H \cdot H = X(X'X)^{-1}X'X(X'X)^{-1}X' = X(X'X)^{-1}X' = H$$

либо из геометрических соображений: умножение на  $H$  несколько раз подряд, это проецирование результата проецирования. А проекция от проекции совпадает с проекцией.

Собственными числами матрицы  $H$  могут быть только нули или единицы. Действительно, при проецировании часть векторов сохраняются (те, что лежали в пространстве регрессоров), часть превращается в ноль (те, что были ортогональны пространству регрессоров), а все другие при проецировании меняют направление.

Ранг матрицы-шляпницы можно посчитать, воспользовавшись тем, что  $rk(AB) = rk(BA)$ :

$$rk(X(X'X)^{-1}X') = rk(X'X(X'X)^{-1}) = rk(I_{k \times k}) = k$$