

# Статистические свойства оценок

Эконометрика. Openedu. Неделя 2

- стандартные предпосылки для модели линейной регрессии
- доверительные интервалы для коэффициентов
- гипотезы о коэффициентах

# Условное математическое ожидание

$r$  — одна случайная величина

$s$  — одна случайная величина

$E(s|r)$  — это такая функция от случайной величины  $r$ , которая наиболее похожа на случайную величину  $s$

$E(s|r)$  — это случайная величина  $\tilde{s}$ :

- ❶ представимая в виде  $\tilde{s} = f(r)$
- ❷  $E(\tilde{s}) = E(s)$
- ❸  $Cov(s - \tilde{s}, g(r)) = 0$  для любой  $g(r)$ .

Или:  $Cov(s, g(r)) = Cov(\tilde{s}, g(r))$

Теорема:

Если величина  $r$  дискретна и принимает значения  $a$ ,  $b$  или  $c$ , то

$$E(s|r) = \begin{cases} E(s|r = a), & \text{если } r = a \\ E(s|r = b), & \text{если } r = b \\ E(s|r = c), & \text{если } r = c \end{cases}$$

## Задача [у доски]

$s, r$	$r = 1$	$r = 2$
$s = 0$	0.25	0.2
$s = 10$	0.25	0.3

Найдите:  $E(s|r)$ ,  $E(s^2|r)$

# Если величины непрерывны и есть совместная функция плотности

Теорема:

Если пара величин  $x, y$  имеет функцию плотности  $f(r, s)$ , то

$$E(s|r) = \int_{-\infty}^{\infty} s \cdot f(s|r) dx$$

где  $f(s|r) = f(r, s)/f(r)$  — условная функция плотности

Пусть  $a, b$  — константы,  $s, r$  — случайные величины.

Идея: свойства  $E(s|r)$  аналогичны свойствам  $E(s)$ , если считать  $r$  и любую функцию  $h(r)$  константой.



- $E(E(s|r)) = E(s)$
- $E(as + b|r) = aE(s|r) + b$
- $E(h(r)|r) = h(r)$
- $E(h(r)s|r) = h(r)E(s|r)$

# Условная дисперсия и ковариация

Обычная дисперсия:  $Var(s) = E(s^2) - (E(s))^2$

Условная дисперсия:  $Var(s|r) = E(s^2|r) - (E(s|r))^2$

Обычная ковариация:  $Cov(s_1, s_2) = E(s_1 s_2) - E(s_1)E(s_2)$

Условная ковариация:  $Cov(s_1, s_2|r) = E(s_1 s_2|r) - E(s_1|r)E(s_2|r)$

## Задача [у доски]

$s, r$	$r = 1$	$r = 2$
$s = 0$	0.25	0.2
$s = 10$	0.25	0.3

Найдите:  $Var(s|r)$

# Свойства условной дисперсии

Пусть  $a, b$  — константы,  $s, r$  — случайные величины.

Идея: свойства  $\text{Var}(s|r)$  аналогичны свойствам  $\text{Var}(s)$ , если считать  $r$  и любую функцию  $h(r)$  константой.


$$\text{Var}(as + b|r) = a^2 \text{Var}(s|r)$$

$$\text{Var}(s + h(r)|r) = \text{Var}(s|r)$$

$$\text{Var}(h(r)s|r) = h^2(r) \text{Var}(s|r)$$

$$\text{Var}(s) = \text{Var}(E(s|r)) + E(\text{Var}(s|r))$$

# Геометрическая интерпретация [у доски]



# Мораль геометрической интерпретации:

Если считать, что  $Cov(r, s)$  — скалярное произведение, то

- квадрат длины случайной величины  $r$  — дисперсия,  $Var(r)$
- косинус угла между случайными величинами — корреляция,  $Corr(s, r)$

Верны “школьные” теоремы: теорема Пифагора, Фалеса, etc

- $E(\varepsilon_i|X) = 0$
- $E(\varepsilon_i^2|X) = \sigma^2$  или  $Var(\varepsilon_i|X) = \sigma^2$
- $E(\varepsilon_i\varepsilon_j|X) = 0$  или  $Cov(\varepsilon_i, \varepsilon_j|X) = 0$



Ковариационная матрица вектора  $\varepsilon$ :

$$Var(\varepsilon) = \begin{pmatrix} Var(\varepsilon_1) & Cov(\varepsilon_1, \varepsilon_2) & Cov(\varepsilon_1, \varepsilon_3) & \dots \\ Cov(\varepsilon_2, \varepsilon_1) & Var(\varepsilon_2) & Cov(\varepsilon_2, \varepsilon_3) & \dots \\ Cov(\varepsilon_3, \varepsilon_1) & Cov(\varepsilon_3, \varepsilon_2) & Var(\varepsilon_3) & \dots \\ \vdots & & & \end{pmatrix}$$

## Запись предпосылок с помощью ковариационной матрицы

$$\text{Var}(\varepsilon|X) = \begin{pmatrix} \sigma^2 & 0 & 0 & \dots \\ 0 & \sigma^2 & 0 & \dots \\ 0 & 0 & \sigma^2 & \dots \\ \vdots & \vdots & \vdots & \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & 0 & 0 & \dots \\ 0 & 1 & 0 & \dots \\ 0 & 0 & 1 & \dots \\ \vdots & \vdots & \vdots & \end{pmatrix} = \sigma^2 \cdot I_{n \times n}$$

# Дисперсия и ковариация оценок коэффициентов

Предпосылки:

- $Var(\varepsilon|X) = \sigma^2 \cdot I_{n \times n}$
- $Var(\varepsilon_i|X) = \sigma^2$
- $Cov(\varepsilon_i, \varepsilon_j|X) = 0$
- $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$

Позволяют посчитать  $Var(\hat{\beta}_j|X)$ ,  $Cov(\hat{\beta}_j, \hat{\beta}_l|X)$

## Пример вычислений в парной регрессии [у доски]

В модели  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$

Предположим, что:  $\text{Var}(\varepsilon_i|X) = \sigma^2$ ,  $\text{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$

Найдите  $\text{Var}(\hat{\beta}_2|X)$ ,  $\text{Cov}(\hat{\beta}_1, \hat{\beta}_2|X)$ ,  $\text{Var}(\hat{\beta}_1|X)$

## Итого в парной регрессии:

- $Var(\hat{\beta}_2|X) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$
- $Cov(\hat{\beta}_1, \hat{\beta}_2|X) = \frac{-\bar{x}\sigma^2}{\sum (x_i - \bar{x})^2}$
- $Var(\hat{\beta}_1|X) = \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}$

- Зачем придумали эту условную дисперсию, если все свойства аналогичны обычной дисперсии?
- А вот как раз и придумали, чтобы всё аналогично просто считалось! Настоящая безусловная дисперсия оценок коэффициентов — гораздо сложнее, чем условная.

## Теорема (без доказательства):

$$\text{Var}(\hat{\beta}_j|X) = \sigma^2 / \text{RSS}_j$$

$\text{RSS}_j$  — сумма квадратов остатков в регрессии  $j$ -ой объясняющей переменной на остальные объясняющие переменные (включая константу)

# ЛИНАЛ. Ковариационная матрица оценок коэффициентов

Средствами линейной алгебры можно доказать, что:

$$\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$$



# ЛИНАЛ. Предварительная информация к доказательству:

Свойство:  $Var(Ay) = A \cdot Var(y) \cdot A'$

Это матричный аналог свойства  $Var(a \cdot y_1) = a^2 \cdot Var(y_1)$ .

Напомним, что  $(AB)' = B'A'$  и  $(A^{-1})' = (A')^{-1}$

Поэтому:

- $(X'X)' = X'X'' = X'X$
- $((X'X)^{-1})' = (X'X)^{-1}$

# ЛИНАЛ. доказательство формулы [у доски]

Если оценки МНК существуют и единственны,  $\text{Var}(\varepsilon|X) = \sigma^2 I_{n \times n}$   
то ковариационная матрица равна:

$$\text{Var}(\hat{\beta}|X) = \sigma^2 (X'X)^{-1}$$

# Как оценить $\sigma^2$ ?

Константа  $\sigma^2$  неизвестна.

Случайная величина  $\hat{\sigma}^2 = \frac{RSS}{n-k}$  — замечательная оценка для  $\sigma^2$ .

Замечательная в смыслах:

- $E(\hat{\sigma}^2) = \sigma^2$ , в среднем оценивает верно
- $\hat{\sigma}^2 \rightarrow \sigma^2$  по вероятности с ростом  $n$

# Оценка ковариационной матрицы

Идея: заменим во всех формулах  $\sigma^2$  на  $\hat{\sigma}^2$ :

- Истинная дисперсия:  $\text{Var}(\hat{\beta}_j|X) = \sigma^2 \cdot f(X)$
- Оценка дисперсии:  $\widehat{\text{Var}}(\hat{\beta}_j|X) = \hat{\sigma}^2 \cdot f(X)$

а именно:  $\widehat{\text{Var}}(\hat{\beta}_j|X) = \hat{\sigma}^2 / \text{RSS}_j$

- $\text{se}(\hat{\beta}_j) = \sqrt{\widehat{\text{Var}}(\hat{\beta}_j|X)}$

Например, в модели  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$ :  $\text{se}(\hat{\beta}_2) = \sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}$

$$\widehat{Var}(\hat{\beta}|X) = \begin{pmatrix} \widehat{Var}(\hat{\beta}_1|X) & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2|X) & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_3|X) & \dots \\ \widehat{Cov}(\hat{\beta}_2, \hat{\beta}_1|X) & \widehat{Var}(\hat{\beta}_2|X) & \widehat{Cov}(\hat{\beta}_2, \hat{\beta}_3|X) & \dots \\ \widehat{Cov}(\hat{\beta}_3, \hat{\beta}_1|X) & \widehat{Cov}(\hat{\beta}_3, \hat{\beta}_2|X) & \widehat{Var}(\hat{\beta}_3|X) & \dots \\ \vdots & & & \end{pmatrix}$$

- ЛИНЛА:  $\widehat{Var}(\hat{\beta}|X) = \hat{\sigma}^2 \cdot (X'X)^{-1}$
- В R: `vcov(model)`

- Базовые:

верны даже на малых выборках без предположения о нормальности  $\varepsilon_i$

- Асимптотические:

верны на больших выборках даже без предположения о нормальности  $\varepsilon_i$

- При нормальности:

верны при нормальности  $\varepsilon_i$  даже на малых выборках

Если:

- ❶ Истинная зависимость имеет вид  $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$ 
  - В матричном виде:  $y = X\beta + \varepsilon$
- ❷ С помощью МНК оценивается регрессия  $y$  на константу,  $x_i$ ,  $z_i$ 
  - В матричном виде:  $\hat{\beta} = (X'X)^{-1}X'y$
- ❸ Наблюдений больше, чем оцениваемых коэффициентов  $\beta$ :  $n > k$

# БСХС — предположения на $\varepsilon_i$ :

Если:

- ❶ Строгая экзогенность:  $E(\varepsilon_i | \text{все регрессоры}) = 0$ 
  - В матричном виде:  $E(\varepsilon_i | X) = 0$
- ❷ Условная гомоскедастичность:  $E(\varepsilon_i^2 | \text{все регрессоры}) = \sigma^2$ 
  - В матричном виде:  $E(\varepsilon_i^2 | X) = \sigma^2$
- ❸  $\text{Cov}(\varepsilon_i, \varepsilon_j | X) = 0$  при  $i \neq j$



Если:

- 7 векторы отдельных наблюдений  $(x_i, z_i, y_i)$  — независимы и одинаково распределены
- 8 с вероятностью 1 среди регрессоров нет линейно зависимых
- Синонимы в матричном виде:  $\text{rank}(X) = k$  или  $\det(X'X) \neq 0$  или  $(X'X)^{-1}$  существует

То:

- Оценки  $\hat{\beta}_j$  линейны по  $y_i$ :  $\hat{\beta}_j = c_1 y_1 + \dots + c_n y_n$
- Оценки несмещены:  $E(\hat{\beta}_j|X) = \beta_j$ , и в частности  $E(\hat{\beta}_j) = \beta_j$

То:

- Оценки эффективны среди линейных и несмещенных

Для любой линейной по  $y_i$  и несмещенной альтернативной оценки  $\hat{\beta}^{alt}$ :

$$Var(\hat{\beta}_j^{alt}|X) \geq Var(\hat{\beta}_j|X) \text{ и } Var(\hat{\beta}_j^{alt}) \geq Var(\hat{\beta}_j)$$

То:

- Ковариационная матрица:  $\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$

Дисперсии:  $\text{Var}(\hat{\beta}_j|X) = \sigma^2/RSS_j$

- $\text{Cov}(\hat{\beta}_j, \hat{\varepsilon}_i|X) = 0$
- $E(\hat{\sigma}^2|X) = \sigma^2$ , и  $E(\hat{\sigma}^2) = \sigma^2$

То при  $n \rightarrow \infty$ :

- $\hat{\beta}_j \rightarrow \beta_j$  по вероятности
- $\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \rightarrow N(0, 1)$  по распределению
- $\hat{\sigma}^2 \rightarrow \sigma^2$  по вероятности

$$\hat{\sigma}^2 = \frac{RSS}{n-k}$$

Если дополнительно известно, что  $\varepsilon_i \sim N(0, \sigma^2)$ , то:

- Оценки эффективны среди несмещенных
- $\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} | X \sim t_{n-k}, \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}$
- $RSS / \sigma^2 | X \sim \chi^2_{n-k}, RSS / \sigma^2 \sim \chi^2_{n-k}$

# Доверительные интервалы для коэффициентов

Возможно строить в двух подходах:

- Асимптотически:  $t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \rightarrow N(0, 1)$
- При нормальности:  $t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}$

Примерный 95%-ый интервал:

$$[\hat{\beta}_j - 2se(\hat{\beta}_j); \hat{\beta}_j + 2se(\hat{\beta}_j)]$$

# Описание любого теста:

- предпосылки теста

например: асимптотический или требующий нормальности ошибок  $\varepsilon_i$

- проверяемая  $H_0$  против  $H_a$
- формула для вычисления статистики
- закон распределения статистики при верной  $H_0$



# Практическая последовательность действий

- 1 выбираем уровень значимости  $\alpha$ ,  
 $\alpha = P(H_0 \text{ отвергнута} \mid H_0 \text{ верна})$
- 2 находим наблюдаемое значение статистики  $S_{obs}$
- 3 находим критическое значение статистики  $S_{cr}$
- 4 сравниваем критическое и наблюдаемое  $S_{obs}$  и  $S_{cr}$

(можно сравнить Р-значение и уровень значимости  $\alpha$ )

- 5 вывод: “ $H_0$  отвергается” или “ $H_0$  не отвергается”

# Проверка гипотез и построение доверительных интервалов [у доски]

```
summary(model)
```

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	59.86392	3.98754	15.013	<2e-16 ***
Agriculture	0.10953	0.07848	1.396	0.1698
Catholic	0.11496	0.04274	2.690	0.0101 *

Residual standard error: 11.07

- проверьте гипотезу  $\beta_a = 0$
- постройте доверительный интервал для  $\beta_a$
- постройте доверительный интервал для  $\sigma^2$

стандартные ошибки часто выписывают под коэффициентами

$$\widehat{Fertility}_i = 59.8 + 0.109 Agriculture_i + 0.115 Catholic_i$$

(3.98)      (0.078)      (0.042)

# Стандартная табличка в любом статистическом пакете [у доски]

Estimate Std. Error t value Pr(>|t|)

(Intercept)	59.86392	3.98754	15.013	<2e-16 ***
Agriculture	0.10953	0.07848	1.396	0.1698
Catholic	0.11496	0.04274	2.690	0.0101 *

# Особые моменты при проверки гипотез

- Плохое устоявшееся название гипотез
- Смысл формулировки “ $H_0$  не отвергается”
- Значимость и существенность — разные вещи
- Проблема множественных сравнений

Проверка значимости — на самом деле проверка незначимости:

- “Мы проверили значимость коэффициента при доходе”
- Мы проверили  $H_0 : \beta_{inc} = 0$ .

# Смысл “ $H_0$ не отвергается”

- недостаточно данных чтобы отвергнуть  $H_0$
- имеющиеся данные не противоречат  $H_0$

Вполне возможно, что данные не противоречат  $H_a$  (!)

- Коэффициент может быть значимым и совершенно несущественным

На огромных выборках как правило все коэффициенты значимы

- Коэффициент может быть существенным, но незначимым

Значимость — статистическое отвержение гипотезы о точном равенстве

Существенность — насколько данное отличие от нуля важно в прикладном смысле



# Стандартизированные коэффициенты

Существенность — можно придать разный математический смысл  
Например:

- стандартизировать переменные:

$$y_i^{st} := \frac{y_i - \bar{y}}{sd(y)}, \quad x_i^{st} := \frac{x_i - \bar{x}}{sd(x)}, \quad z_i^{st} := \frac{z_i - \bar{z}}{sd(z)}$$

- переоценить модель:

$$y_i^{st} = \beta_1^{st} + \beta_2^{st} x_i^{st} + \beta_3^{st} z_i^{st} + \varepsilon_i^{st}$$

# Проблема множественных сравнений

- Исследователь хочет проверить гипотезу о том, что  $\beta_{42} = 0$ . Ok.
- Исследователь хочет выяснить какие регрессоры из 100 значимы.  
Плохой метод.

# Проверка гипотезы об одном ограничении

Хотим проверить гипотезу о  $\beta_2 - \beta_3$ .

Статистика  $t = \frac{\hat{\beta}_2 - \hat{\beta}_3 - (\beta_2 - \beta_3)}{se(\hat{\beta}_2 - \hat{\beta}_3)}$  распределена

- асимптотически  $N(0, 1)$
- при нормальности  $t_{n-k}$

Хотим проверить гипотезу  $\beta_2 = \beta_3$  или  $\beta_2 - \beta_3 = 0$

Всегда можно переформулировать модель так, что  $\beta_2 - \beta_3$  станет новым коэффициентом  $\beta'_2 = \beta_2 - \beta_3$ .

# Пример проверки гипотезы о связи коэффициентов [у доски]

```
summary(model)
      Estimate Std. Error t value Pr(>|t|)
(Intercept) 59.86392    3.98754  15.013  <2e-16 ***
Agriculture  0.10953    0.07848   1.396   0.1698
Catholic     0.11496    0.04274   2.690   0.0101 *
vcov(model)
      (Intercept) Agriculture Catholic
(Intercept) 15.900471817 -0.256680712 -0.006998292
Agriculture -0.256680712  0.006159437 -0.001345371
Catholic    -0.006998292 -0.001345371  0.001826622
Residual standard error: 11.07
```

Проверьте гипотезу  $\beta_a = \beta_c$  (два способа)

## Мораль лекции 2:

В этой лекции мы научились:

- строить доверительные интервалы
- проверять гипотезы об отдельном коэффициенте
- сформулировали стандартные предпосылки

В следующей:

- более сложные гипотезы
- прогнозирование

# Источники мудрости:

- Артамонов Н.В., Введение в эконометрику: главы 1.3
- Борзых Д.А., Демешев Б.Б. Эконометрика в задачах и упражнениях: глава 2, 3
- Катышев П.К., Пересецкий А. А. Эконометрика. Начальный курс: главы 2.4, 2.5, 2.6, 3.2, 3.3
- Себер Дж., Линейный регрессионный анализ: главы 3.2, 3.3, 3.4